

¹

Bloom Filter

²

Jambura Anna, Pürstinger Kathrin,
Schnappauf Franziska, Thiele Coco

³

26. Februar 2026

⁴

Zusammenfassung

⁵

passend auszufüllen

⁶ 1 Grundlagen und Motivation

⁷ 1.1 Das Membership-Problem

⁸ Seien ein beliebiges Element x und eine Menge S gegeben. Das Membership-Problem ist
⁹ eine Bezeichnung für die Fragestellung: „Ist das Element x Teil der Menge S ?“ Diese Frage
¹⁰ tritt in vielen verschiedenen Bereichen und Anwendungen auf. Einige Beispiele dafür
¹¹ sind Datenbankenabfragen und URL-Caching in Web-Browsern. Klassische Ansätze, wie
¹² Listen, Hashtabellen oder Suchbäume liefern eine exakte Antwort auf die Frage, jedoch
¹³ benötigen sie alle entsprechend viel Zeit und Speicherplatz. [1]

¹⁴ 1.2 Lösungsansatz - Bloomfilter

¹⁵ Bloomfilter wurden 1970 von Burton H. Bloom entwickelt, um den hohen Ressourcen-
¹⁶ bedarf zu umgehen. Sie sind probabilistische Datenstrukturen, das bedeutet sie arbeiten
¹⁷ mit Wahrscheinlichkeiten anstatt absoluter Sicherheit.

¹⁸ Dabei erlauben sie False-Positives in einem begrenzten Ausmaß. Ein Filter kann also
¹⁹ fälschlicherweise melden, das Element x sei Teil der Menge S , auch wenn dies nicht der
²⁰ Fall ist. Umgekehrt sind False-Negatives jedoch ausgeschlossen. Wenn x tatsächlich ein
²¹ Element von S ist, wird das der Filter immer korrekt erkennen. Mit anderen Worten:
²² Ein vorhandenes Element wird nie als „nicht vorhanden“ gemeldet. [2]

²³ 1.3 Trade-off

²⁴ Bloomfilter balancieren drei zentrale Faktoren. Neben der Reject-Time (Zeit zur Ab-
²⁵ lehnung von Nicht-Mitgliedern) und dem benötigten Speicherplatz, die auch in konven-
²⁶ tionellen Hashing-Methoden berücksichtigt werden müssen, wird hier auch die erlaubte
²⁷ Fehlerrate betrachtet. Der zentrale Trade-off ist dabei zwischen dem akzeptablen Anteil
²⁸ an False-Positives und der Speichereffizienz. Dieser ist bei der Implementierung eines
²⁹ Bloomfilters individuell konfigurierbar.

³⁰ Durch die kontrollierte Fehlerwahrscheinlichkeit wird der Speicherbedarf bedeutend re-
³¹ duziert, da er nicht von der Länge der Daten abhängt, sondern immer gleich viele Bits
³² pro Element beträgt. Je niedriger die Fehlerrate gewählt ist, desto mehr Bits pro Element
³³ werden benötigt. Bloomfilter sind besonders hilfreich, wenn die Mehrheit der Anfragen
³⁴ nicht-existente Elemente betrifft – hier liefern sie schnell ein definitives „Nein“ auf die
³⁵ Membership-Frage. [1]

36 2 Funktionsweise und Mathematische Grundlagen

37 2.1 Aufbau

38 Der Bloomfilter besteht auf einem m -stelligen Bitarray, welches initial mit Nullen befüllt
39 wird. Weiters werden k unabhängige Hashfunktionen definiert. Diese verwendet man um
40 die Elemente der gewünschten Menge zu hashen. Abhängig von ihrem Hashwert werden
41 die Elemente dann an der entsprechenden Position im Array eingefügt. Um also jedes
42 Element erfolgreich einzufügen, muss die Hasfunktion $\text{mod } m$ angewandt werden. Somit
43 erreicht man die Indizes 0 bis $m - 1$. [2]

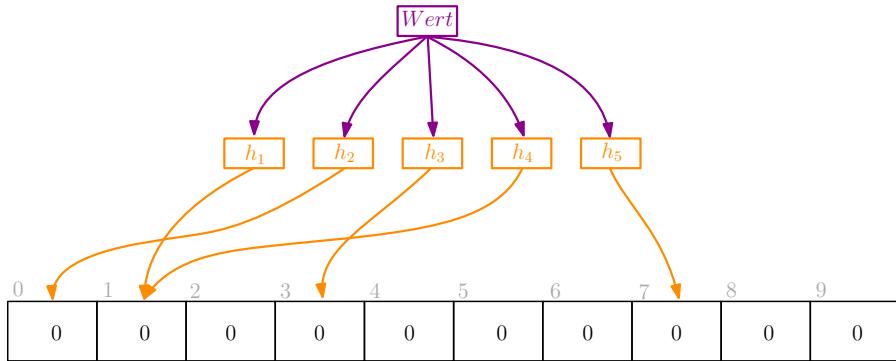


Abbildung 1: Visualisierung eines Bloomfilters

44 Da die Hashfunktionen keinem Sicherheitsstandard entsprechen, müssen keine krypto-
45 graphischen Eigenschaften gelten. Kryptographische Eigenschaften bedeutet, minimale
46 Eingabeänderungen müssen zu einer maximalen Änderung des Hashwerts führen. Die
47 Eingabe darf nicht mittels der Hashfunktion wiederhergestellt werden können und zwei
48 Eingaben haben fast unmöglich den selben Hashwert.
49 Für Bloomfilter verwendet man schnelle und einfache Hashfunktionen, da die Effizienz
50 im Vordergrund steht.

51 2.2 Einfügen/Suchen

52 Einfügen

53 Eine Menge S wird nun wie folgt in einem Bloomfilter eingefügt:

54 Für jedes Element $x \in S$ werden die Hash Werte aller k Hash Funktionen berechnet.
55 Nun wird an diesen Positionen im Array die 0 auf eine 1 gesetzt. Sollte an einer dieser
56 Positionen bereits eine 1 stehen, wird dies ignoriert. Dieser Vorgang wird für alle n
57 Elemente der Menge S wiederholt.

⁵⁸ **2.2.1 Beispiel Einfügen**

- ⁵⁹ Betrachte folgende Menge $S = \{2, 4, 9\}$ und einen Bloomfilter der Länge $m = 10$ mit
⁶⁰ $k = 3$ Hashfunktionen.
⁶¹ Als beispielhafte Hashfunktionen verwenden wir: $h_1(x) = x \bmod 10$ $h_2(x) = (2x+3) \bmod 10$ und
⁶² $h_3(x) = (3x+7) \bmod 10$.
⁶³ Nun berechnen wir die Hashwerte für jedes Element der Menge S :

- ⁶⁴ • Für $x = 2$:

$$h_1(2) = 2 \bmod 10 = 2$$

$$h_2(2) = (2 \cdot 2 + 3) \bmod 10 = 7$$

$$h_3(2) = (3 \cdot 2 + 7) \bmod 10 = 3$$

- ⁶⁵ • Für $x = 4$:

$$h_1(4) = 4 \bmod 10 = 4$$

$$h_2(4) = (2 \cdot 4 + 3) \bmod 10 = 1$$

$$h_3(4) = (3 \cdot 4 + 7) \bmod 10 = 9$$

- ⁶⁶ • Für $x = 9$:

$$h_1(9) = 9 \bmod 10 = 9$$

$$h_2(9) = (2 \cdot 9 + 3) \bmod 10 = 1$$

$$h_3(9) = (3 \cdot 9 + 7) \bmod 10 = 4$$

- ⁶⁷ Nun fügt man die Elemente in den Bloomfilter ein. Für das erste Element 2 werden die
⁶⁸ Positionen 2, 7 und 3 auf 1 gesetzt. Daraus resultiert der folgende Bloomfilter:

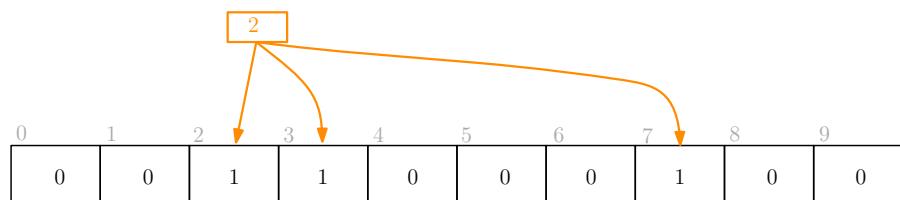


Abbildung 2: Bloomfilter nach Einfügen des Elements 2

⁶⁹

70 Für das zweite Element 4 werden die Positionen 4, 1 und 9 auf 1 gesetzt.

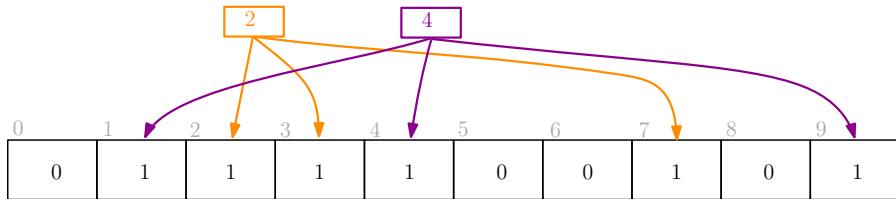


Abbildung 3: Bloomfilter nach Einfügen des Elements 4

71 Für das dritte Element 9 werden die Positionen 9, 1 und 4 auf 1 gesetzt. Da die Positionen
72 1, 4 und 9 bereits auf 1 gesetzt wurden, ändert sich der Bloomfilter nicht weiter.

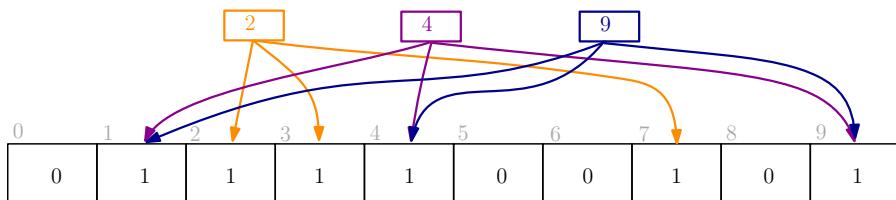


Abbildung 4: Bloomfilter nach Einfügen des Elements 9

73

74 Suchen

75 Um ein Element x in einem Bloomfilter zu suchen, werden dieselben Hashfunktionen wie
76 beim Einfügen verwendet. Die Hashwerte werden berechnet und an den entsprechenden
77 Positionen im Array geprüft. Wenn alle Positionen auf 1 gesetzt sind, so ist das Element
78 wahrscheinlich in der Menge enthalten. Wenn mindestens eine Position auf 0 gesetzt ist,
79 so ist das Element sicher nicht in der Menge enthalten. [2]

80 2.2.2 Beispiel Suchen

81 Betrachten wir den zuvor erstellten Bloomfilter und suchen nach dem Element 4. Be-
82 rechnen wir die Hashwerte für 4:

$$h_1(4) = 4 \bmod 10 = 4$$

$$h_2(4) = (2 \cdot 4 + 3) \bmod 10 = 1$$

$$h_3(4) = (3 \cdot 4 + 7) \bmod 10 = 9$$

83 Nun prüfen wir die Positionen 4, 1 und 9 im Bloomfilter. Alle drei Positionen sind auf
84 1 gesetzt, daher ist das Element 4 wahrscheinlich in der Menge enthalten.

85 Betrachten wir nun das Element 5 und berechnen die Hashwerte:

$$\begin{aligned} h_1(5) &= 5 \bmod 10 = 5 \\ h_2(5) &= (2 \cdot 5 + 3) \bmod 10 = 3 \\ h_3(5) &= (3 \cdot 5 + 7) \bmod 10 = 2 \end{aligned}$$

86 Nun prüfen wir die Positionen 5, 3 und 2 im Bloomfilter. Die Position 2 ist auf 0 gesetzt,
87 daher ist das Element 5 sicher nicht in der Menge enthalten.

88 Ein wichtiger Aspekt des Bloomfilters ist, dass er fälschlicherweise angeben kann, dass
89 ein Element in der Menge enthalten ist, obwohl es tatsächlich nicht vorhanden ist. Dies
90 wird als *False Positive* bezeichnet. Wenn alle Positionen, die durch die Hashfunktionen
91 eines Elements angegeben werden, auf 1 gesetzt sind, obwohl das Element nicht in der
92 Menge enthalten ist, führt dies zu einem False Positive. Ein Beispiel hierfür wäre das
93 Element 12:

$$\begin{aligned} h_1(12) &= 12 \bmod 10 = 2 \\ h_2(12) &= (2 \cdot 12 + 3) \bmod 10 = 7 \\ h_3(12) &= (3 \cdot 12 + 7) \bmod 10 = 3 \end{aligned}$$

94 Die Positionen 2, 7 und 3 sind alle auf 1 gesetzt, obwohl das Element 12 nicht in der
95 Menge enthalten ist. Daher würde der Bloomfilter fälschlicherweise angeben, dass 12 in
96 der Menge enthalten ist.

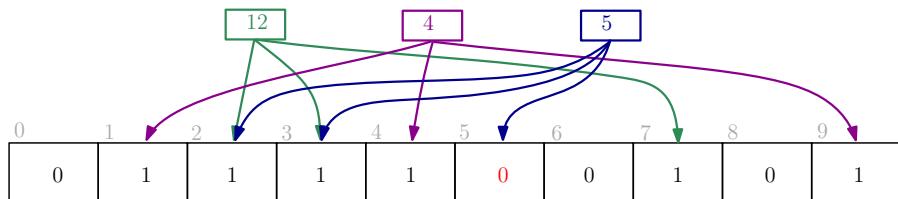


Abbildung 5: Suchen nach den Elementen 4, 5 und 12 im Bloomfilter

97 2.3 Formeln zur Evaluierung

98 2.3.1 False Positive Probability

99 Zur Erstellung des optimalen Bloomfilter ist es wichtig, die False Positive Probability
100 (FPP) zu berechnen. Diese gibt an, wie wahrscheinlich es ist, dass der Bloomfilter fälsch-
101 licherweise angibt, dass ein Element in der Menge enthalten ist, obwohl es tatsächlich
102 nicht vorhanden ist. Laut [2] entsteht die Formel zur Berechnung aus folgenden Kompo-
103 nenten:

¹⁰⁴ Unter der Annahme, dass die Hashfunktionen unabhängig und gleichverteilt sind, ergibt
¹⁰⁵ sich die Wahrscheinlichkeit dass ein bestimmtes der m Bits nicht gesetzt ist durch:

$$1 - \frac{1}{m} \quad (1)$$

¹⁰⁶ Weiters werden nun die k Hashfunktionen mitbetrachtet, immer noch für den Fall, dass
¹⁰⁷ ein bestimmtes Bit nicht gesetzt ist.

$$\left(1 - \frac{1}{m}\right)^k \quad (2)$$

¹⁰⁸ Nun werden die n Elemente der Menge S betrachtet, welche in den Bloomfilter eingefügt
¹⁰⁹ werden.

$$\left(1 - \frac{1}{m}\right)^{kn} \quad (3)$$

¹¹⁰ Die Wahrscheinlichkeit, dass ein bestimmtes Bit auf 1 gesetzt ist, ergibt sich aus der
¹¹¹ Gegenwahrscheinlichkeit:

$$1 - \left(1 - \frac{1}{m}\right)^{kn} \quad (4)$$

¹¹² Da es bei Bloomfiltern um Membership-Tests geht, muss die Wahrscheinlichkeit berech-
¹¹³ net werden, dass alle k Positionen eines Elements auf 1 gesetzt sind, obwohl das Element
¹¹⁴ nicht in der Menge enthalten ist.

$$\left(1 - \left(1 - \frac{1}{m}\right)^{kn}\right)^k \quad (5)$$

¹¹⁵ Aus der Formel lässt sich schließen, dass je **größer** m gewählt wird, desto **kleiner** wird
¹¹⁶ die False Positive Probability. Je **größer** n gewählt wird, desto **größer** wird die False
¹¹⁷ Positive Probability.

¹¹⁸ Da die False Positive Probability so klein wie möglich gehalten werden soll, ist auch
¹¹⁹ die Wahl der Anzahl Hashfunktionen von großer Bedeutung. Setzt man die Formel für
¹²⁰ die False Positive Probability gleich 0 und löst sie nach k auf, erhält man die optimale
¹²¹ Anzahl an Hashfunktionen:

$$k_{opt} = \frac{m}{n} \ln 2 \approx \frac{9m}{13n} \quad (6)$$

¹²² 3 Pseudocode und Implementierung

¹²³ Ein Bloom-Filter lässt sich mit drei grundlegenden Operationen beschreiben: Initialisierung, Einfügen und Abfragen.

¹²⁵ 3.1 Initialisierung

¹²⁶ Bei der Initialisierung werden alle m Bits im Array auf 0 gesetzt und k Hash-Funktionen festgelegt. Je kleiner die gewünschte Fehlerrate ist, desto größer muss m gewählt werden.

Algorithm 1 Initialisierung eines Bloom-Filters

- 1: Erzeuge Bit-Array $B[0 \dots m - 1]$ und setze alle Bits auf 0
 - 2: Definiere Hash-Funktionen h_1, h_2, \dots, h_k
-

¹²⁹ 3.2 Einfügen

¹³⁰ Beim Einfügen wird für jedes Element x eine Schleife genau k -mal ausgeführt. In jeder Iteration wird mithilfe der jeweiligen Hash-Funktion h_i ein Index berechnet und das entsprechende Bit im Bitarray auf 1 gesetzt. Der Modulo-Operator stellt sicher, dass der berechnete Index immer innerhalb des gültigen Bereichs von 0 bis $m - 1$ liegt. [2]

Algorithm 2 Einfügen eines Elements x

- 1: **for** $i = 1$ **to** k **do**
 - 2: $index \leftarrow h_i(x) \bmod m$
 - 3: $B[index] \leftarrow 1$
 - 4: **end for**
-

¹³⁴ 3.3 Abfragen

¹³⁵ Für eine Abfrage werden dieselben k Hash-Werte berechnet und die entsprechenden Positionen im Array überprüft. Existiert mindestens ein Bit mit dem Wert 0, kann man mit absoluter Sicherheit sagen, dass das Element nicht enthalten ist – es gibt keine False Negatives. Sind hingegen alle k Bits gleich 1, gilt das Element als wahrscheinlich enthalten. Diese probabilistische Aussage ist das zentrale Merkmal des Bloom-Filters:
¹³⁹ Es sind False Positives möglich.

Algorithm 3 Abfrage eines Elements x

```
1: for  $i = 1$  to  $k$  do
2:    $index \leftarrow h_i(x) \bmod m$ 
3:   if  $B[index] = 0$  then
4:     return FALSE
5:   end if
6: end for
7: return TRUE
```

¹⁴¹ **4 Komplexitätsanalyse**

¹⁴² **4.1 Zeitkomplexität**

¹⁴³ Sowohl das Einfügen als auch das Abfragen eines Elements haben eine Zeitkomplexität
¹⁴⁴ von $\mathcal{O}(k)$, wobei k die Anzahl der Hash-Funktionen bezeichnet. Entscheidend ist dabei,
¹⁴⁵ dass diese Zeit *unabhängig* von der Anzahl n der bereits im Filter gespeicherten Elemente
¹⁴⁶ ist. Der Grund dafür liegt in der Struktur des Filters: Es werden keine Elemente explizit
¹⁴⁷ gespeichert, sondern lediglich Bits in einem Array der Größe m gesetzt oder gelesen.
¹⁴⁸ Egal ob sich 1.000 oder 100 Millionen Elemente im Filter befinden – die Abfragezeit
¹⁴⁹ bleibt konstant [1].

¹⁵⁰ **4.2 Speicherkomplexität**

¹⁵¹ Die Speicherkomplexität beträgt $\mathcal{O}(m)$, wobei m die Größe des Bit-Arrays ist. Im Ge-
¹⁵² gensatz zu klassischen Datenstrukturen hängt dieser Speicherbedarf *nicht* von der Größe
¹⁵³ der gespeicherten Elemente ab, sondern nur von zwei Faktoren: der Anzahl der zu spei-
¹⁵⁴ chernden Elemente n und der akzeptierten False-Positive-Rate ε [1].

¹⁵⁵ Als praktische Faustregel gilt: Bei einer Fehlerrate von etwa 1% benötigt ein Bloom-
¹⁵⁶ Filter weniger als 10 Bits pro Element. Das ist bemerkenswert effizient – unabhängig
¹⁵⁷ davon, ob es sich bei den Elementen um kurze Zeichenketten oder lange URLs han-
¹⁵⁸ delt [3].

¹⁵⁹ **4.3 Vergleich mit anderen Datenstrukturen**

¹⁶⁰ Tabelle 1 stellt die Komplexitätseigenschaften des Bloom-Filters denen einer Hash-
¹⁶¹ Tabelle mit verketteten Listen sowie eines balancierten Baums gegenüber.

¹⁶² Die **Hash-Tabelle mit verketteten Listen** erreicht im Durchschnitt $\mathcal{O}(1)$ für Einfüge-
¹⁶³ und Suchoperationen, kann im schlechtesten Fall jedoch auf $\mathcal{O}(n)$ anwachsen. Da jedes
¹⁶⁴ Element explizit gespeichert wird, beträgt der Speicherbedarf $\mathcal{O}(n)$ – typischerweise
¹⁶⁵ 64 Bits oder mehr pro Element (Nutzdaten plus Pointer). Der wesentliche Vorteil liegt

Eigenschaft	Bloom-Filter	Hash-Tabelle mit Chaining	Balancierter Baum
Zeitkomplexität	$\mathcal{O}(k)$	$\emptyset \mathcal{O}(1)$, worst $\mathcal{O}(n)$	$\mathcal{O}(\log n)$
Speicherkomplexität	$\mathcal{O}(m)$	$\mathcal{O}(n)$	$\mathcal{O}(n)$
Genauigkeit	Probabilistisch	Exakt	Exakt

Tabelle 1: Vergleich ausgewählter Datenstrukturen

₁₆₆ in der Exaktheit: Es gibt keine False Positives, und Elemente können jederzeit wieder
₁₆₇ abgerufen werden [4].

₁₆₈ Der **balancierte Baum** hat eine Zeitkomplexität von $\mathcal{O}(\log n)$ für Suche und Einfügen.
₁₆₉ Die Laufzeit steigt mit wachsender Elementanzahl langsam an, da bei jedem Schritt etwa
₁₇₀ die Hälfte der verbleibenden Elemente verworfen wird. Der Speicherbedarf ist ebenfalls
₁₇₁ $\mathcal{O}(n)$. Der Vorteil liegt in der Möglichkeit, Elemente geordnet zu speichern, was zusätz-
₁₇₂ liche Operationen wie Bereichsabfragen erlaubt [4].

₁₇₃ 4.4 Speichereffizienz in der Praxis

₁₇₄ Um die Speicherersparnis greifbar zu machen, betrachten wir ein konkretes Beispiel:
₁₇₅ Für 100 Millionen URLs benötigt ein Bloom-Filter bei einer Fehlerrate von 1% rund
₁₇₆ 120 Megabyte. Eine Hash-Tabelle mit denselben Einträgen würde hingegen über ein
₁₇₇ Gigabyte beanspruchen. Das ist nicht nur ein quantitativer, sondern oft ein qualitativer
₁₇₈ Unterschied – nämlich der zwischen einem System, das auf einem Endgerät lauffähig ist,
₁₇₉ und einem, das einen dedizierten Server erfordert.

₁₈₀ Dieser enorme Vorteil hat allerdings seinen Preis: Ein Bloom-Filter beantwortet aus-
₁₈₁ schließlich die Frage „*Ist das Element möglicherweise in der Menge?*“ Er kann weder
₁₈₂ Elemente aufzählen noch löschen, noch gibt er die Elemente selbst zurück [2].

¹⁸³ 5 Probleme von Bloom-Filtern und Lösungen

¹⁸⁴ 5.1 Das Löschen von Elementen

¹⁸⁵ Der klassische Bloom-Filter besitzt unter anderem die Einschränkung, dass er das Lö-
¹⁸⁶ schen von Elementen nicht unterstützt. Möchte man ein Element entfernen, liegt es
¹⁸⁷ zunächst nahe, die entsprechenden Bits im Bit-Array wieder auf 0 zu setzen. Genau
¹⁸⁸ hier entsteht jedoch ein fundamentales Problem. Mehrere Elemente können auf dieselbe
¹⁸⁹ Position im Bit-Array hashen. Wird ein Bit zurückgesetzt, entfernt man daher nicht nur
¹⁹⁰ das gewünschte Element, sondern gleichzeitig auch alle anderen Elemente, die an die-
¹⁹¹ ser Position gespeichert wurden. Das eigentliche Element ist zwar entfernt, aber andere
¹⁹² Elemente gelten nun ebenfalls als nicht mehr vorhanden, obwohl sie eigentlich noch im
¹⁹³ Filter sein sollten.

¹⁹⁴ Eine Lösung für dieses Problem ist der Counting Bloom Filter. [5] Das Grundprinzip
¹⁹⁵ beim Einfügen bleibt dabei gleich wie beim klassischen Bloom-Filter. Der Unterschied
¹⁹⁶ besteht darin, dass man an jeder Position nicht nur ein einzelnes Bit speichert, sondern
¹⁹⁷ einen kleinen Zähler. Dieser Zähler wird beim Einfügen eines Elements um 1 erhöht und
¹⁹⁸ beim Löschen wieder um 1 verringert. Typischerweise sind diese Zähler 4 Bit groß und
¹⁹⁹ können somit Werte von 0 bis 15 speichern. Dadurch wird es möglich, Elemente sicher
²⁰⁰ zu löschen, ohne andere Einträge unbeabsichtigt zu beeinflussen.

²⁰¹ Allerdings hat der Counting Bloom Filter auch Nachteile. Der Speicherverbrauch ist
²⁰² deutlich höher, da statt eines einzelnen Bits nun 4 Bits pro Position benötigt werden.
²⁰³ Bei gleicher Genauigkeit benötigt ein Counting Bloom Filter somit ungefähr das Drei-
²⁰⁴ bis Vierfache an Speicher im Vergleich zum klassischen Bloom-Filter. Außerdem können
²⁰⁵ die Zähler überlaufen. Wenn mehr als 15 Elemente auf dieselbe Position hashen, reichen
²⁰⁶ 4 Bits nicht mehr aus. Man könnte größere Zähler verwenden, allerdings würde das den
²⁰⁷ Speicherbedarf weiter erhöhen. Der Counting Bloom Filter eignet sich daher besonders
²⁰⁸ dann, wenn häufig gelöscht werden muss - man bezahlt diese Möglichkeit jedoch mit
²⁰⁹ einem deutlich höheren Speicherverbrauch. An Verbesserungen wird zwar gearbeitet,
²¹⁰ doch eine genauere Betrachtung würde den Rahmen dieser Arbeit sprengen.[6]

²¹¹ 5.2 Größenplanung

²¹² Ein weiteres grundlegendes Problem klassischer Bloom-Filter ist die Größenplanung. In
²¹³ der Regel muss man vorher festlegen, wie groß der Filter sein soll. Ist er zu klein dimen-
²¹⁴ sioniert, steigt die Fehlerwahrscheinlichkeit stark an. Die Bits werden sehr schnell gesetzt
²¹⁵ und die False-Positive-Rate nimmt deutlich zu. Ist der Filter hingegen zu groß gewählt,
²¹⁶ wird Speicherplatz verschwendet, da möglicherweise Kapazitäten reserviert werden, die
²¹⁷ nie vollständig genutzt werden.

²¹⁸ Der Scalable Bloom Filter bietet hier eine Lösung durch dynamisches Wachstum. [5] Er
²¹⁹ besteht aus mehreren klassischen Bloom Filtern, die nacheinander erstellt werden. Sobald

220 ein Filter eine bestimmte Auslastung erreicht, wird ein neuer, größerer Filter mit einer
221 strengeren Fehlerrate hinzugefügt. Auf diese Weise bleibt die Gesamtfehlerwahrschein-
222 lichkeit über alle Filter hinweg kontrollierbar. Selbst wenn mehrere Filter hinzukommen,
223 bleibt die kombinierte Fehlerrate in akzeptablen Grenzen. Der große Vorteil ist, dass
224 der Filter beliebig wachsen kann, ohne komplett neu aufgebaut werden zu müssen. Ein
225 Nachteil ist jedoch, dass Abfragen mit jedem zusätzlichen Filter etwas langsamer werden,
226 da mehrere Filter überprüft werden müssen. Neben Counting- und Scalable-Varianten
227 gibt es noch viele weitere spezielle Varianten von Bloom-Filtern, die jedoch den Rahmen
228 dieser Arbeit überschreiten würden.[7]

229 6 Cuckoo Filter

230 Eine alternative Datenstruktur stellt der Cuckoo Filter dar. Hierbei handelt es sich nicht
231 mehr wirklich um einen Bloom-Filter, dennoch verfolgt er dasselbe Ziel: speichereffiziente
232 Mengenabfragen bei geringen Fehlerraten. Der Cuckoo Filter basiert nicht auf einem
233 Bit-Array, sondern auf einer Hash-Tabelle mit kleinen Fächern, sogenannten Buckets. In
234 diesen Buckets werden Fingerabdrücke, sogenannte Fingerprints, gespeichert. Das sind
235 kurze, eindeutige Kennungen der Elemente mit nur wenigen Bits Länge.

236 Beim Einfügen eines Elements wird mithilfe einer Hash-Funktion berechnet, in welches
237 Fach es gehört. Jedes Element besitzt dabei genau zwei mögliche Buckets, in denen
238 es abgelegt werden kann. Ist in einem dieser Buckets noch Platz vorhanden, wird der
239 Fingerprint dort gespeichert. Sind jedoch beide Buckets belegt, greift das sogenannte
240 Cuckoo-Prinzip. Hier verdrängt das neue Element einen bestehenden Eintrag aus einem
241 der beiden Buckets. Das verdrängte Element muss sich anschließend einen neuen Platz
242 in seinem alternativen Bucket suchen. Dieser Prozess kann sich fortsetzen, bis schließlich
243 alle Elemente einen Platz gefunden haben.

244 Der Cuckoo Filter bringt sowohl Vorteile als auch Nachteile mit sich. Ein großer Vorteil
245 ist, dass Elemente problemlos gelöscht werden können, da die Fingerprints direkt gespei-
246 chert sind und gezielt entfernt werden können. Außerdem sind Abfragen sehr schnell, da
247 nur zwei Buckets geprüft werden müssen. Ein Nachteil zeigt sich bei sehr hoher Auslas-
248 tung der Hash-Tabelle. In solchen Fällen kann die Verdrängungskette sehr lang werden,
249 ohne dass ein freier Platz gefunden wird. Dann muss die gesamte Struktur vergrößert wer-
250 den. Studien zeigen jedoch, dass Cuckoo Filter in vielen realen Anwendungen praktisch
251 besser abschneiden als klassische Bloom-Filter.[8] Klassische Bloom-Filter sind dennoch
252 besonders sinnvoll, wenn sehr große Datenmengen verarbeitet werden, der verfügbare
253 Speicher knapp oder teuer ist, kleine Fehlerraten akzeptiert werden können und sie als
254 Vorfilter von aufwendigen oder rechenintensiven Operationen eingesetzt werden. [4]

255 7 Anwendungsbeispiele

256 7.1 Web-Proxy-Caching

257 In verteilten Netzwerken arbeiten mehrere Proxy-Server zusammen und tauschen sich
258 untereinander aus. Bei einer Anfrage nach einer Webseite sucht ein Proxy zunächst im
259 eigenen Cache, ob er diese bereits gespeichert hat. Wenn das nicht der Fall ist, spricht
260 man von einem Cache-Miss und es wird geprüft, ob sich die Webseite im Cache eines
261 anderen Proxys befindet. Wird sie hier gefunden, wird die Anfrage an den entsprechenden
262 Proxy weitergeleitet, anstatt die Seite direkt aus dem Web zu laden.

263 Damit dieses System funktioniert, muss jeder Proxy über den Inhalt der Caches aller
264 anderen Proxies Bescheid wissen. Um den enormen Netzwerkverkehr, der beim wieder-
265 holten Austausch der kompletten URL-Listen entstehen würde, zu vermeiden, kommen
266 hier Bloomfilter zum Einsatz. Im Summary Cache Protokoll tauschen Proxies periodisch
267 Bloomfilter untereinander aus, die den Inhalt ihres Caches zusammenfassen. Wenn nun
268 ein Cache-Miss auftritt, werden die Bloomfilter jener anderen Proxies konsultiert, die
269 ein positives Ergebnis versprechen und die Anfrage wird entsprechend weitergeleitet.

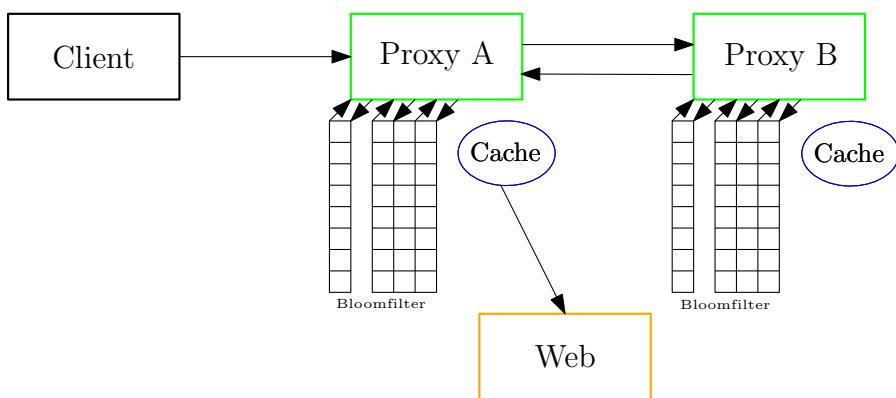


Abbildung 6: Web-Proxy-Caching mit Bloomfiltern

270 Hierbei können False-Positives auftreten, wobei es dann zu einer minimalen Verzögerung
271 kommt. Die massive Reduktion des Netzwerkverkehrs durch den Bloomfilter überwiegt
272 diesen Nachteil bei Weitem. Das Summary Cache Protokoll wird beispielsweise im Web-
273 Proxy-Cache „Squid“ eingesetzt. [4]

274 7.2 Google Bigtable

275 Bloomfilter werden oft in Datenbanksystemen verwendet, wobei Google Bigtable ein
276 bekanntes Beispiel hierfür ist. Bigtable speichert die Daten auf der Festplatte in Sorted-
277 String-Tables (SSTables). Wenn eine Leseoperation durchgeführt werden soll, müssen

278 potenziell mehrere dieser Tables durchsucht werden, bis die gewünschten Daten gefunden werden. Da jede Table auf der Festplatte liegt, verursacht jeder Zugriff auf eine 280 SSTable auch einen teuren Festplattenzugriff. Besonders problematisch im Bezug auf 281 die benötigten Ressourcen wird dies bei Abfragen nach nicht-existenten Daten.

282 Kommen jetzt die Bloomfilter zum Einsatz, ändert sich dies drastisch. Für jede SSTable 283 wird ein Bloomfilter im Hauptspeicher gehalten, der Auskunft über deren Inhalt gibt. 284 Vor einem Festplattenzugriff wird also der Filter befragt, ob die gesuchten Daten in 285 der Table enthalten sind. Bei einem positiven Ergebnis wird der Zugriff durchgeführt, 286 ansonsten kann er eingespart werden. [9]

287 7.2.1 Beispiel Anfrage

288 Angenommen es wird eine Anfrage auf den Schlüssel X gestellt und auf der Festplatte 289 liegen drei SSTables. Ohne Verwendung von Bloomfiltern müssten alle drei Tables abgerufen und durchsucht werden, also drei Festplattenzugriffe durchgeführt werden. Unter 291 Einsatz von Bloomfiltern werden jedoch zuerst diese konsultiert. Die ersten beiden Filter 292 könnten melden, dass Schlüssel X jeweils nicht in SSTable 1 bzw. SSTable 2 liegt, 293 sie können also beide übersprungen werden. Filter 3 sagt jetzt, dass sich X in Table 3 294 befinden könnte – dieser Zugriff wird durchgeführt. Demzufolge wurde nur ein Festplattenzugriff durchgeführt, bis der gesuchte Schlüssel X gefunden wurde, das bedeutet eine 295 Ersparnis von zwei Zugriffen durch die Verwendung von Bloomfiltern. 296

297 7.3 Weitere Anwendungen

298 Heute kommen Bloomfilter in zahlreichen Systemen zum Einsatz. Google Chrome nutzt 299 sie beispielsweise für Safe-Browsing zur Malware-Erkennung. [10] Neben Google Bigtable 300 setzen auch weitere Datenbanksysteme, wie Apache Cassandra auf die Vorteile von 301 Bloomfiltern, um unnötige Festplattenzugriffe zu vermeiden. [11]

302 **Literatur**

- 303 [1] Burton H. Bloom. Space/time trade-offs in hash coding with allowable errors.
304 *Commun. ACM*, 13(7):422–426, 1970.
- 305 [2] Sasu Tarkome, Christian Esteve Rothenberg, and Eemil Lagerspetz. Theory and
306 practice of bloom filters for distributed systems. *IEEE Communications Surveys &*
307 *Tutorials*, 14(1):131–155, 2012.
- 308 [3] Li Fan, Pei Cao, Jussara Almeida, and Andrei Z Broder. Summary cache: A scalable
309 wide-area web cache sharing protocol. *IEEE/ACM Transactions on Networking*, 8
310 (3):281–293, 2000.
- 311 [4] Andrei Broder and Michael Mitzenmacher. Network applications of bloom filters:
312 A survey. *Internet Mathematics*, 1(4):485–509, 2004.
- 313 [5] Paul A. Gagniuc, Ionel-Bujorel Păvăloiu, and Maria-Iuliana Dascălu. Bloom filters
314 at fifty: From probabilistic foundations to modern engineering and applications.
315 *Algorithms*, 18:1–15, 2025.
- 316 [6] Flavio Bonomi, Michael Mitzenmacher, Rina Panigrahy, Sushil Singh, and George
317 Varghese. An improved construction for counting bloom filters. In *Proceedings of
318 the 14th conference on Annual European Symposium on Algorithms*, pages 684–695.
319 Springer, 2006.
- 320 [7] Paulo S. Almeida, Carlos Baquero, Nuno Preguiça, and David Hutchison. Scalable
321 bloom filters. *Information Processing Letters*, 101(6):255–261, 2007.
- 322 [8] Bin Fan, David G. Andersen, Michael Kaminsky, and Michael D. Mitzenmacher.
323 Cuckoo filter: Practically better than bloom. In *Proceedings of the 10th ACM Inter-
324 national Conference on Emerging Networking Experiments and Technologies*, pages
325 179–190. ACM, 2014.
- 326 [9] Fay Chang, Jeffrey Dean, Sanjay Ghemawat, Wilson C. Hsieh, Deborah A. Wallach,
327 Mike Burrows, Tushar Chandra, Andrew Fikes, and Robert E. Gruber. Bigtable:
328 A distributed storage system for structured data. *ACM Trans. Comput. Syst.*, 26
329 (2), 2008.
- 330 [10] Thomas Gerbet, Amrit Kumar, and Cédric Lauradoux. (un)safe browsing. Technical
331 Report RR-8594, INRIA, 2010.
- 332 [11] Avinash Lakshman and Prashant Malik. Cassandra: a decentralized structured
333 storage system. *SIGOPS Oper. Syst. Rev.*, 44(2):35–40, 2010.